

Relazione - Versione 2: Rete Neurale Multiclasse

Dataset	Task	Acc. train	Acc. test
Fashion-MNIST	10 classi	83,13%	83,42%

Introduzione

La Versione 2 estende il primo modello binario al problema completo Fashion-MNIST a 10 classi. L'obiettivo è mantenere lo stesso ciclo di apprendimento trasparente, sostituendo il singolo output sigmoid con 10 punteggi di classe e probabilità softmax.

Il modello resta volutamente semplice: non ci sono layer nascosti. Ogni immagine viene mappata direttamente da 784 valori di pixel normalizzati a 10 punteggi di output.

Obiettivo della Versione 2

L'obiettivo principale è comprendere la classificazione multiclasse: come il modello rappresenta 10 classi, trasforma i punteggi in probabilità, misura l'errore multiclasse e aggiorna una matrice di pesi e un vettore di bias.

Dati e Preparazione

Il progetto utilizza il dataset Fashion-MNIST in formato CSV. Il file di training contiene 60.000 immagini etichettate e il file di test separato contiene 10.000 immagini etichettate. Ogni immagine in scala di grigi 28 x 28 è rappresentata da 784 valori di pixel.

Vengono utilizzate tutte le 10 classi. I valori dei pixel sono normalizzati da 0-255 a 0-1 dividendo per 255. Le etichette intere vengono inoltre convertite in vettori one-hot per la cross-entropy multiclasse.

Architettura

Il flusso della Versione 2 è:

784 pixel -> 10 punteggi lineari -> softmax -> probabilità di classe -> predizione argmax

Output Multiclasse

I pesi formano ora una matrice 784 x 10 e il bias contiene 10 valori. Per ogni immagine, il passaggio lineare produce 10 punteggi grezzi, uno per ciascuna classe Fashion-MNIST.

$$z = X @ W + b$$

Attivazione Softmax

La softmax trasforma i 10 punteggi grezzi in 10 probabilità che sommano a 1. La classe predetta è l'indice della probabilità più alta.

Cross-Entropy e Discesa del Gradiente

La cross-entropy multiclasse misura quanta probabilità il modello assegna alla classe corretta. La discesa del gradiente aggiorna poi tutti i pesi e i bias nella direzione che riduce questa loss.

Il learning rate è 0,1. Il training si ferma quando il miglioramento della loss diventa inferiore a $\text{tol} = 1e-4$. Questa tolleranza è un compromesso pratico: un valore più piccolo può migliorare leggermente l'accuratezza, ma richiede più iterazioni full-batch e quindi più tempo di esecuzione.

Risultato del Training

Con questa semplice architettura lineare, la loss finale di training è circa 0,5092 e l'accuratezza di training è 83,13%.

Valutazione

Il file di test Fashion-MNIST separato viene normalizzato nello stesso modo. Si calcolano le probabilità softmax e argmax seleziona una classe da 0 a 9. L'accuratezza sul test è 83,42%.

Risultati

Metric	Value
Training loss	0.5092
Training accuracy	83,13%
Test accuracy	83,42%

Cosa Insegna la Versione 2

La Versione 2 mostra come il ciclo di apprendimento binario si generalizza a piu classi senza introdurre layer nascosti. Un singolo layer lineare riesce gia ad apprendere separazioni utili tra le classi, ma resta limitato alle relazioni rappresentabili da questa mappatura diretta dai pixel agli output.

Introduce inoltre i componenti multiclasse fondamentali usati dalle reti piu grandi: target one-hot, probabilita softmax, cross-entropy multiclasse, matrice dei pesi e predizione con argmax.

Compromesso tra Accuratezza e Tempo

La tolleranza di arresto $tol = 1e-4$ mantiene questa implementazione didattica ragionevolmente veloce. Ridurre la tolleranza prolunga il training e puo migliorare leggermente il risultato, ma aumenta anche il tempo di esecuzione. Questo compromesso verra affrontato naturalmente con l'evoluzione dell'architettura.

Limiti

La Versione 2 non ha layer nascosti, usa gradient descent full-batch e apprende soltanto una mappatura lineare dai 784 pixel di input alle 10 classi. Non puo quindi ancora apprendere rappresentazioni non lineari piu ricche delle immagini.

Conclusione

La Versione 2 estende con successo il progetto da un modello binario a singolo neurone a un classificatore Fashion-MNIST completo a 10 classi. Il modello raggiunge 83,13% di accuratezza sul training e 83,42% sul test mantenendo l'implementazione compatta e completamente trasparente.

L'evoluzione naturale successiva e aumentare la capacita rappresentativa della rete mantenendo la stessa logica di apprendimento costruita da zero.